

大模型及机器人算法- VLA技术分解

2025


A stylized, colorful illustration of a city skyline at night, featuring various skyscrapers and buildings in shades of blue, purple, and pink. The skyline is positioned behind the large numbers '2025', which are rendered in a vibrant pink-to-blue gradient. The entire scene is set against a dark blue background with subtle radial light patterns emanating from the top.



01

VLA技术分解

机器人整机系统架构



VLM模型与VLA模型



VLA（左）被视为“全程可求导”的统一架构， “全程可求导”（Fully Differentiable）
而传统的E2E+VLM（右）则被视为“非全程可求导”的双系统拼凑

VLM的“非”端到端本质

其核心问题在于：VLM的输出端是文本（Text），而非轨迹（Trajectory）


VLA的“真”端到端

在算法形式上，回归并坚守了从（传感输入）到（轨迹输出）的端到端神经网络形式；“全程可求导”（Fully Differentiable）

VLA将两个并行的、解耦的系统（3D编码器->动作解码器 和 2D编码器->LLM），重构为一个统一的、串行的“V -> L -> A”单一模型（空间智能 -> 语言智能 -> 行动策略）

VLA的通用技术栈：积木是如何搭建的？

VLA：视觉编码器（V）、语言编码器（L）和动作解码器（A）



VLA的三大核心组件：视觉编码器（Visual Encoder）、大型语言模型（Large Language Model，即L模块）和动作解码器（Action Decoder）

视觉编码器 (V): VLA的“眼睛”

在当今的技术栈中，这个角色的最佳选择，几乎被**ViT** (Vision Transformer) 及其变体所垄断。而ViT的强大，又来自于其特定的“预训练”方式。

VLA领域最受青睐的ViT主要有两种：**CLIP/SigLIP** 和 **DINOv2**

1. CLIP / SigLIP: 提供“内容识别”能力 (“What is it?”)

- **核心功能**: CLIP (及其优化版SigLIP) 的核心是 **强大的视觉-文本对齐** (visual-text alignment) 能力。它擅长将图像中的像素与描述这些像素的自然语言单词联系起来。
- **训练方式**: 它们通过海量的“图像-文本”配对数据进行“对比学习” (Contrastive Learning)。简单来说，它们学习到了“这段文字描述的就是这张图片”。
- **SigLIP的优势**: SigLIP是CLIP的直接升级版。它用更简单、扩展性更好的**Sigmoid损失函数**，取代了CLIP复杂的Softmax损失函数，训练过程更高效，且在更大规模数据集上表现更好，从而实现了“更简单，效果更好”。
- **VLA中的角色**: SigLIP主要为VLA提供了“**识别和描述图像内容**”的能力。它负责告诉“大脑”：“我看到了一个红色的瓶子”或“这是一条狗，脖子上有牵引绳”。

2. DINOv2: 提供“空间理解”能力 (“Where is it? How is it positioned?”)

核心功能: DINOv2 的核心是**强大的空间理解和高级视觉语义能力**。**训练方式**: 它是一种**自监督学习** (Self-Supervised Learning) 模型。它**不需要**文本标签，而是通过一种名为“自蒸馏” (self-distillation) 的方式进行训练。这种方式强迫模型去理解图像的**内在空间结构** (例如，一张猫的左耳和右耳在空间上的关系，即使没有任何文字告诉它这是“猫”或“耳朵”)。


VLA中的角色: DINOv2主要为VLA提供了“**空间推理能力**”。它负责告诉“大脑”：“那个红色的瓶子**在碗的左边**，并且是**竖立**着的”，或者“那只狗**正坐着**，它的牵引绳**延伸到了草地上**”。

视觉编码器 (V): VLA的“眼睛”

VLA领域最受青睐的ViT主要有两种: CLIP/SigLIP 和 DINOv2

3. 顶尖方案: SigLIP + DINOv2 双编码器

既然SigLIP擅长“识别内容”(What), 而DINOv2擅长“理解空间”(Where/How), 那么最强大的VLA视觉系统, 自然是将两者互补的优势结合起来。



OpenVLA的视觉编码器架构。它同时并联使用了DinoV2和SigLIP, 将两者的特征(features)融合后, 再送入MLP Projector (MLP投影器)

这正是OpenVLA、Prismatic-7B 等顶尖VLA模型所采用的“双编码器”策略:

视觉编码器 (V): VLA的“眼睛”

VLA领域最受青睐的ViT主要有两种：[CLIP/SigLIP](#) 和 [DINOv2](#)

3. 顶尖方案：SigLIP + DINOv2 双编码器

- 1. 并行编码：** 原始图像被同时输入到SigLIP和DinoV2两个独立的视觉编码器中。
- 2. 特征提取：** SigLIP输出包含丰富“内容”信息的特征向量，DinoV2输出包含精确“空间”信息的特征向量。
- 3. 特征融合：** 这两种不同类型的特征向量在通道维度上被“连接”（Concatenated）在一起，形成一个同时包含“是什么”和“在哪里/怎么样”的“综合性的视觉表示”（comprehensive visual representation）。
- 4. 模态对齐-关键步骤：** 最后，这个“综合视觉特征”必须被“翻译”成“大脑”（L模块，即LLM）能够理解的“语言”。这个关键的“翻译”步骤由一个MLP Projector（多层感知机投影器）完成。该投影器负责将高维的视觉特征向量，投影（映射）到与LLM处理文本时使用的相同的“令牌”（Token）嵌入空间中。

通过这种“双编码器 + MLP投影器”的精密设计，VLA的“眼睛”就为“大脑”提供了最完美的输入：一个既知道“**是什么**”（来自SigLIP），也知道“**在哪里/怎么样**”（来自DinoV2）的、且“大脑”能够直接理解的视觉信息流。

理想汽车MindVLA的实现方式：拥抱3D高斯建模 (3DGS)

MindVLA的V模块核心是：

1. **3D高斯建模-3D Gaussian Splatting, 3DGS**：它没有使用SigLIP或DINOv2，而是直接采用了基于3D高斯球的场景表示方法。这种方法旨在从多视图2D图像中，重建出更精细、更连续的3D场景。
2. **自监督3D编码器预训练-Self-Supervised 3D Encoder Pretraining**：其V模块通过自监督的方式，直接从传感器数据（包括摄像头Cameras, 激光雷达Lidar等）通过3D Encoder 生成统一的Scene Representation（场景表示）。

3D Tokenizer / 3D Projector：最终，这个基于3DGS的场景表示，通过3D Projector（3D投影器）或3D Tokenizer 被转换为MindGPT（L模块）可以理解的Token。

对比总结：


- **通用方案-SigLIP + DINOv2**：更侧重于从2D图像中提取内容和空间语义，并通过MLP投影器与LLM对齐。
- **MindVLA方案-3DGS**：更侧重于直接进行高保真的3D场景重建，为“从零预训练”的L模块提供更原生、更丰富的3D空间输入。

这两种不同的V模块实现路径，也反映了VLA架构仍在快速发展，不同的团队在根据自身的技术积累和目标进行着不同的探索。

语言编码器 (L): VLA的“大脑”

接收来自“眼睛”（V模块）的**视觉令牌**（Visual Token）和来自用户的**文本令牌**（Text Token），在模型内部将这两者“**融合**”（Fuse），并进行复杂的**跨模态推理**（Cross-modal Reasoning）。


“大脑”的主流选择：LLaMA家族与Qwen等



- **LLaMA家族（核心主导）：** 这是目前VLA领域的**绝对主流**。
 - LLaMA-2：被广泛认为是开源VLA模型的“标配”。例如，OpenVLA 和 Prismatic-7B 都明确使用了Llama 2 7B 作为其语言主干（backbone）。
 - Vicuna：作为LLaMA最著名的微调变体之一，Vicuna因其强大的对话和推理能力而被广泛采用。ORION 架构的LLM就是Vicuna v1.5。
- **Qwen系列（重要力量）：** 阿里巴巴的Qwen系列也在VLA领域扮演着重要角色。
 - OpenDriveVLA使用了Qwen-2.5。
 - SimLingo使用了Qwen-2。
 - Impromptu VLA和AutoVLA则都采用了Qwen-2.5VL。理想汽车早期IM系统也使用了基于Qwen（千问）的VLM。
- **其他家族（展现多样性）：** 当然，GPT系列和Gemma等也在VLA模型中占有一席之地，验证了VLA架构的灵活性。
 - EMMA使用了Gemini。
 - LangCoop使用了GPT-4o。
 - VaVIM使用了GPT-2。
 - Pi-0和FAST模型使用了Gemma-2B。

语言编码器 (L): VLA的“大脑”

“大脑”是如何工作的？——融合与推理



OpenVLA的L模块 (Llama 2 7B) 接收两路输入：一路是来自Llama Tokenizer的“文本指令”，另一路是来自MLP Projector的“视觉特征”。

1. **融合 (Fusion)**：L模块 (LLM) 的输入是一个组合序列。这个序列的前半部分是来自“眼睛” (V模块) 的视觉Token (即被MLP Projector“翻译”过的视觉特征)，后半部分是来自“用户”的文本Token (例如“Put eggplant in bowl”，即“把茄子放进碗里”)。
2. **推理 (Reasoning)**：一旦输入融合，LLM就会像处理普通文本一样，在“视觉”和“文本”Token之间进行复杂的“自注意力” (Self-Attention) 计算。
 - 在ORION 这样的高级架构中，L模块的输入甚至还包括了来自QT-Former 的“历史Token”。
 - 此时，LLM会执行后续的高级推理任务，如“场景分析” (Scene Analysis)、**“动作推理” (Action Reasoning)** 和 **“历史回顾” (History Review)**。

语言编码器 (L)：VLA的“大脑”

“大脑”的输出：从“思考”到“指令”

VLA “大脑”的革命性在于它的输出。

它输出的不是用于聊天的文本，而是一个（或一系列）高度浓缩的、机器可读的“动作令牌”（Action Token）或“规划令牌”（Planning Token）。

这个“Token”就是L模块（大脑）“思考”的最终结晶。它代表了一个明确的“意图”或“决策”（例如“抓取红色物体”或“执行减速让行策略”）。这个“意图”将被传递给A模块（“手脚”），由A模块去解码和执行。

“大脑”的优化：LoRA与MoE

在车端或机器人上部署一个70亿（7B）参数的LLM 是一个巨大的工程挑战。为了让“大脑”既聪明又高效，业界采用了两种主流的优化策略：

- **LoRA-Low-Rank Adaptation**：这是ORION(小米的实现) 采取的策略 。即冻结（Frozen）庞大的Vicuna 主体参数，只在旁边“外挂”一个极小的、可训练的LoRA适配器。这使得VLA的微调成本和部署灵活性大大降低，是一种“轻量化”的改装方案 。

这里面理想汽车MindVLA的与ORION 等模型采用开源LLM（如Vicuna ）+ LoRA 轻量化微调的“改装”路线不同，理想汽车的MindVLA 选择了更彻底的“从零开始打造LLM” 的“自研”路线，其L模块被称为MindGPT。

理想汽车的L模块称为MindGPT

MindGPT 的核心特点在于其**针对3D驾驶场景的原生设计**：

- 1. 原生3D输入**：MindGPT的输入不是经过MLP Projector “翻译”的2D图像特征，而是来自V模块 的、通过3D Projector 或3D Tokenizer 处理的“3D高斯特征”（3D Gaussian Features）。它的“母语”就是3D空间。
- 2. 面向驾驶的预训练**：MindGPT在预训练阶段就学习驾驶相关的物理因果律，例如通过“未来帧预测”（Next Frame Prediction）和“CoT（条件输出）”等任务进行训练。
- 3. 为车端优化的架构**：为了在车端芯片上实现实时推理，MindGPT内部采用了**MoE**（混合专家）+ 稀疏注意力（Sparse Attention）架构，通过Router（路由器）实现稀疏激活，大幅降低了计算量。
- 4. 高效动作输出**：在输出“Action Tokens”（动作令牌）时，MindGPT采用了“并行解码”（Parallel Decoding）技术，在一个步骤内同时生成所有动作指令（如转向、油门等），满足了实时性要求。

对比总结：

- 通用方案-如小米ORION**：通常采用开源LLM + LoRA微调。优点是开发速度快，可利用社区成果；缺点是LLM底层可能缺乏对3D物理世界的原生理解。
- MindVLA方案-MindGPT**：采用从零预训练。优点是模型天生为3D驾驶设计，与V模块（3DGS）结合更紧密，性能潜力可能更高；缺点是研发投入巨大。

动作解码器 (A): VLA的“手脚”

“动作解码器”（Action Decoder, A模块）的核心任务，就是接收来自“大脑”（L模块）的那个高度浓缩的“意图”Token，并将其“解码”（Decode）成一系列真实、物理、可执行的控制信号，例如机器人的 $[\Delta x, \Delta \theta, \Delta \text{Grip}]$ （7D动作）或自动驾驶的“Trajectories”（轨迹）。

“黄金标准”：基于扩散的Transformer（Diffusion Transformer）

在所有技术中，“基于扩散的Transformer”（Diffusion-based Transformer）是目前VLA模型中“最受青睐”（most favored）的动作解码器方案。

- **代表模型**：Octo、理想汽车的MindVLA（其A-Action Policy核心就是一个“Diffusion Decoder”）以及小米/华科的ORION（它也将Diffusion作为一个核心的“Generative Planner”选项）都采用了这一思路。
- **为何是它**？因为Diffusion模型（AIGC绘画的核心技术）极其擅长“**建模复杂多模态动作分布**”。
 - **解释**：驾驶或机器人操作往往不是一个“唯一解”。面对一个障碍物，你可以“向左绕一点”、“向左绕很多”或者“减速等待”。Diffusion模型天生就能理解并生成这种“多模态”的概率分布，而不是只给出一个僵硬的单一答案。
- **如何工作**？它通过一种名为“迭代去噪”（Iterative Denoising）的方式工作。
 - **流程**：从一堆随机的“噪声”（Noise）出发，在“大脑”（L模块）输出的“Action Token”或“Planning Token”的约束和引导下，逐步将噪声“还原”成一条（或多条）符合意图的、最优的轨迹。
- **核心优势**：这种“生成式”的轨迹，具有无与伦比的“细粒度”和“平滑控制”（fine-grained, smooth control）能力。
 - **“拟人化”轨迹**：这完美地呼应了MindVLA的目标——生成“拟人化”的、“如丝般顺滑”的“黄金轨迹”。正如理想工程师所比喻的“螺旋线”，Diffusion寻找的是物理上最优、最舒适的“变分函数”解，而不是简单的代数曲线。
- **工程挑战**：Diffusion虽然强大，但“迭代去噪”天生就很慢。为了解决这个问题，MindVLA等架构采用了ODE Sampler（常微分方程采样器）等技术，将“去噪”步骤从几百步压缩到“2到3步”，从而满足了实时控制的需求。
- **解决方案** (以MindVLA为例)：为了解决这个速度瓶颈，MindVLA等架构采用了ODE Sampler（常微分方程采样器）等先进的采样技术。
 - **效果**：这些技术极大地加速了Diffusion的生成过程。它们不再需要“成百上千步”，而是可以将轨迹的“收敛”压缩到“大概2到3步内完成”。这个工程上的突破，才使得Diffusion这个强大的生成模型，终于得以被应用于需要实时控制的自动驾驶和机器人领域。

动作解码器 (A): VLA的“手脚”

其他主流方案

虽然Diffusion是“顶配”，但在不同的VLA模型中，也存在其他更简洁、更高效的解码器方案：

- **自回归Transformer头 (Autoregressive Transformer Head) :**
 - **代表模型:** Gato。
 - **工作方式:** 这种解码器就像LLM“写作文”一样，一个Token一个Token地“逐步生成动作序列”。例如，它会先生成“转向Token”，再生成“油门Token”……
 - **核心优势:** 这种方式非常适合“优化实时响应”。
- **MLP预测器头 (MLP Predictor Head) :**
 - **代表模型:** OpenVLA。
 - **工作方式:** 这是最简单直接的方案。L模块输出的“Action Token”，被直接送入一个简单的MLP（多层感知机，即Action De-Tokenizer），由这个MLP直接“映射”出最终的 $[\Delta x, \Delta \theta, \Delta \text{Grip}]$ 等控制数值。
 - **核心优势:** “实现高效低级控制”。它极其轻量，计算速度飞快。ORION的消融实验也将“MLP with Planning Token”作为一个重要的对比基线。
- **嵌入式MPC/规划头 (Embedded MPC / Planning Head) :**
 - **代表模型:** VoxPoser。
 - **工作方式:** VLA的L模块（大脑）不输出具体动作，而是输出一个“目标状态”，然后由一个经典的“模型预测控制”（MPC）或“规划头”来解算这个目标。
 - **核心优势:** “支持动态决策”，能很好地与传统的、经过安全验证的控制理论相结合。

VLA的“积木” V+L+A小结

从简单的MLP，到实时的自回归，再到最强大、最受青睐的Diffusion Transformer，“动作解码器”（A模块）是VLA的最终执行者，负责将“大脑”的意图转化为物理世界的精确动作。理想汽车MindVLA 通过采用先进的Diffusion Transformer 并结合ODE Sampler 加速技术，力求在生成质量和实时性之间达到最佳平衡。

至此，VLA的“积木”已全部分解完毕：

V: 它用强大的**视觉编码器**（如**3DGS** 或**SigLIP+DINOv2**）作为“眼睛”，


L: 用**LLaMA** 或自研模型（如**MindGPT**）作为“大脑”，

A: 用先进的**动作解码器**（如**Diffusion Transformer**）作为“手脚”。

这些最强组件的融合，构建出了这个革命性的“统一大脑”。

VLA的四个进化阶段：从“驾驶解释器”到“决策核心”

Progress of VLA Models for AD



阶段一：语言模型作为“解释器” (Pre-VLA: Language Model as Explainer)

典型架构： 这一阶段的系统通常采用一个冻结的视觉模型（如 CLIP）和一个LLM解码器（如 LLaMA-2）

阶段二：模块化VLA模型 (Modular VLA Models for AD)

典型架构： 如第二幅图所示，系统接收多模态视觉输入（Multimodal Vision），VLM（视觉语言模型）不再只是对外输出文本，而是生成一个“中间表示”（Intermediate Representation）。这个中间表示随后被送入一个独立的“动作头”（Action Head），最终由动作头输出“轨迹”（Trajectory）或“控制”（Control）信号。

阶段三：统一的端到端VLA模型 (Unified End-to-End VLA Models for AD)

典型架构： 如第三幅图所示，阶段二的“VLM”和“动作头”这两个分离的模块被合并成了一个单一的“VLMs”大模型。

阶段四：推理增强的VLA模型 (Reasoning-Augmented VLA Models for AD)

典型架构： 如第四幅图所示，这一阶段的架构演变为“推理VLM与工具使用代理”（Reasoning VLMs & Tool-use Agents）。VLM不再只是一个模型，而是一个可以调用“工具”（如记忆库、规划器）的“智能代理”（Agent）。



02

理想/小米汽车的自动驾驶VLA核心技术栈解析与具身
智能的未来

理想MindVLA：V/L/A三位一体的重构

- **空间智能模块**：输入为多模态传感器数据，使用 3D 编码器提取时空特征，然后将所有传感器与语义信息融合成统一的表征。
- **语言智能模块**：嵌入式部署的大语言模型 **MindGPT**，用于空间 + 语言的联合推理，支持语音指令和反馈，可能实现人车交互。
- **动作策略模块**：使用扩散模型生成车辆未来的行为轨迹，引入噪声来引导扩散过程以生成多样化的动作规划。
- **强化学习模块**：使用 **World Model** 模拟外部环境响应，评估行为后果；使用**奖励模型（Reward Model）**：提供偏好或安全性评估，可能采用人类反馈（RLHF）；使用**闭环学习**根据行为轨迹进行持续优化和泛化。

新架构 (VLA / MindVLA)：统一的、串行的单一模型

- **输入**：同样是摄像头、激光雷达、自车姿态、导航。
- **单一通路**：所有输入信息现在汇入**一条统一的、串行的处理流程**：
- **V (空间智能)**：所有传感器输入首先进入V-Spatial Intelligence模块，通过3D Tokenizer处理，完成统一的3D场景理解与“令牌化”。
- **L (语言智能)**：V模块输出的“3D场景令牌”被送入L-Linguistic Intelligence模块（核心是MindGPT (LLM)），进行基于3D视觉信息的推理和决策。
- **A (行动策略)**：L模块输出的“决策令牌”被送入A-Action Policy模块（核心是Collective Action Generator，如Diffusion），生成最终的Trajectories（轨迹）。
- **核心优势**：这是一个**完全统一**的架构。信息从V无缝流向L，再从L无缝流向A。整个系统可以进行端到端的联合优化，实现了“**强大的空间和语言推理**”与“**行为的集体建模和对齐**”。

理想MindVLA：V (视觉)革命：从BEV到3D高斯建模 (3DGS)

为什么要革命？——BEV的局限性

离散的、有损的、且计算量巨大的

3D高斯建模（3D Gaussian Splatting, 3DGS）技术


3DGS彻底抛弃了“栅格”。它不再试图将连续的世界离散化，而是用一种全新的方式来表示3D场景：将其建模为数百万个微小的、连续的、可微分的“高斯球”（Gaussian）的集合。每一个“高斯球”都包含了精细的位置、形状（椭球）、颜色和透明度信息。通过渲染这些高斯球的集合，就能以极高的保真度和效率重建出逼真的3D场景。

MindVLA V模块的工作流程

步骤一：多源输入融合与特征提取 (Inputs & Encoding)

- **接收多源数据:** 系统首先接收来自车辆多个传感器的原始数据流。这包括高维感知数据，如摄像头（Cameras）的多视图、多帧图像 (T, T-1, T-2, T-3) 和激光雷达（Lidar）的点云，以及低维状态/导航数据，如车辆定位信息（Position）、自车姿态（Ego Pose）和导航信息（Navigation）。
- **并行编码:** 这些不同类型的数据通过不同的编码器并行处理：
 - 高维数据（图像/点云）送入一个强大的3D Encoder (GaussianAD Fig.2 中显示多帧图像 首先经过一个CNN+FPN 提取多尺度特征)。
 - 低维数据（状态/导航）送入另一个相对简单的Encoder。
- **时空特征提取:** 3D Encoder 不仅处理当前帧，还会结合历史帧信息来提取蕴含了丰富时空上下文（Spatio-temporal Context）的3D Features（3D特征）。低维 Encoder 则输出车辆自身状态和目标的特征。这两组特征并不在此步骤融合。

理想MindVLA：V模块的工作流程



步骤二：核心 - 高斯中心场景重建 (Gaussian Refinement Loop)

- **高斯初始化 (Uniform Initialization):** 流程从一个“**高斯均匀初始化**”出发——在3D空间中“撒”下大量随机的初始高斯球（可视化为彩色点云）。
- **迭代优化循环 (Refinement Loop "X B Times"):** 这是生成Scene Representation 的核心。初始高斯球会进入一个**迭代循环**（重复B次），每次循环包含两个关键操作（对应论文中的Gaussian Encoder）：
 - **4D Sparse Convolution:** 用于**高斯球之间的时空交互**。这使得模型能够理解场景的动态变化和高斯球之间的相互关系。
 - **Deformable Cross-Attention:**这个步骤在逻辑上接收**步骤一**中 3D Encoder 输出的 3D Features 作为核心输入，将**步骤一**中从多帧图像提取的视觉特征（3D Features）**融入**到每个高斯球中进行**交叉注意力**的计算。
- **统一输出 (Scene Representation):** 经过B次**自监督学习**（Self-Supervised Pretraining）的迭代优化后，每个高斯球的参数（位置、形状、颜色、透明度、语义）都被**逐步优化**（progressively refine），最终形成了那个统一的、高保真的 **Scene Representation（场景表示）**，这不再是离散的框或栅格，而是一个由数百万优化后的**3D语义高斯球**构成的、**连续**的数字孪生世界。

理想MindVLA：V模块的工作流程

步骤三：优势与应用

- **自监督优势:** 这个核心的Scene Representation是**自监督生成的**。它主要依赖多视图图像之间的一致性等信息学习，**极大地减少了对昂贵人工3D标注的依赖**。
- **统一表示取代中间步骤:** 这个“**稀疏但全面**”的3DGS表示**取代了**传统流程中所有离散的、信息有损的中间步骤（如显式的3D Boxes和Map构建）。
- **直接用于下游任务：** 这个Scene Representation可以直接或经过简单处理后用于后续核心任务的高质量输入：
 - **预测（Prediction）：** 通过一个专门的**Flow Head** 预测每个高斯球未来的位移（即**高斯流 Gaussian Flow**），**从而直接预测未来的Scene Representation**（ $T+1, T+2, T+3$ ），实现对整个场景（包括动静态元素）演化的建模。
 - **规划（Planning）：** 基于对当前和**未来**完整3D场景的深刻理解，规划模块（输入来自Flow Head预测的未来表示）可以直接生成驾驶**轨迹**（Trajectory）。
- **可选的解码路径：** 可以**选择性地**从统一的3DGS表示中解码出传统输出，这些只是**可选的**辅助监督或输出，并非主流程必需。：
 - **密集任务:** 通过**Gaussian-to-Voxel Splatting** 转换为密集体素特征，用于3D Occupancy（3D占用栅格）。
 - **稀疏任务:** 将高斯视为“**语义点云**”，先通过**3D Sparse Convolution** 进一步处理，然后通过**Sparse Max-Pooling** 或其他**Sparse Head**（稀疏头）来输出3D Boxes（3D包围盒）、Map（矢量化地图元素）。
 - **运动任务:** 也可以通过Self-Attention 处理高斯表示来预测Motion（特定物体的运动状态）。

理想MindVLA：V模块的工作流程

步骤四：连接大脑 - 最终投影与Token化 (Projection - Connecting V-Module to L-Module)


- V模块的最后一步是将所有必要信息传递给下游的L模块（语言智能），**3D Projector（3D投影器）** 是这个最终的“接口”和“融合点”。
- **输入**: 它**同时接收**两路输入：
 - 来自高维路径的3D Features，其核心内容是由**步骤二**（高斯中心流程）生成的那个高保真的Scene Representation (即优化后的高斯球集合)。
 - 来自低维路径Encoder的输出，代表车辆自身的状态和导航目标。
- **处理**: 3D Projector 负责将这两路信息**融合**，并将这个融合后的高维、连续表示“**投影**”或“**Token化**”成L模块（如MindGPT）能够理解和处理的输入格式（例如一系列嵌入向量或Token）。

MindVLA的V模块革命全流程：

- 首先并行处理多源传感器输入，通过3D Encoder（利用4D稀疏卷积处理时序）提取高维的3D Features 和低维的状态特征；
- 然后，利用3D Features和初始随机高斯球，通过一个包含4D Sparse Convolution和Deformable Cross-Attention的**自监督迭代优化循环**，生成一个连续、高保真的**3D高斯Scene Representation**，取代了传统的多阶段、离散化感知管道。这个表示是如此丰富，以至于它既可以直接用于下游的“Prediction”（预测）和“Planning”（规划），也可以在需要时（作为可选的监督任务）轻松地从中“解码”出传统的3D占用、3D box、地图或运动信息。
- 最后，这个“3D数字孪生世界”（表示为3D Features）与车辆自身状态特征一起，通过3D Projector 被高效地融合并“翻译”给“大脑”（L模块），为其进行高质量的3D空间推理、未来场景预测（基于Flow Head 输出的高斯流）和规划奠定了坚实无比的基础。

理想MindVLA: L (语言)革命: 从“拿来主义”到“从零预训练”

“从零开始打造LLM”（Crafting LLM from Scratch），并为其“量身定制设计以实现实时边缘推理”（Tailored Design for Real-Time Edge Inference）。其产物就是MindGPT。



MindVLA（即MindGPT）的核心架构。它专为“实时边缘推理”（Real-Time Edge Inference）而设计，从Tokenizer（3D高斯特征）到架构（MoE+稀疏注意力）再到解码方式（Parallel Decoding）都是全新的

理想MindVLA: L (语言)革命

革命点一：专为3D驾驶而生的“训练”

MindVLA的“大脑”在学习“说话”之前，就先学会了“看懂空间”。

- **3D“词汇表” (Tokenizer)**：传统LLM的“词汇表” (Tokenizer) 是“单词”（如apple, car）。而MindGPT的“词汇表”是“**高斯预训练的3D Tokenizer**”。这意味着，它用来“思考”的基本单元，**直接就是V模块（经过3D Projector 处理）输出的“3D高斯特征”**。它的“母语”天生就是3D空间，而不是2D文本。
- **3D“教科书” (Training Task)**：传统LLM的训练任务是“完形填空”或预测下一个单词（如“今天天气很___”）。而MindGPT的训练任务是“**未来帧预测**” (Next Frame Prediction) 和 “**GoT（条件输出）**”。

采用人类思维模式 + 自主切换快思考慢思考，慢思考输出精简的 CoT（采用的固定简短的 CoT 模板） + 输出 action token；快思考直接输出 action token。

这至关重要。它强迫模型不再是“记忆”，而是去“理解”这个世界的**物理因果律**。它必须学会：“如果我（自车）以这个速度，而那辆车（他车）的3D高斯特征在这样变化，那么‘下一帧’的3D高斯特征‘应该’是.....”

通过这种原生3D输入和面向物理的训练任务，MindVLA的L模块在预训练阶段（Pretrained from Scratch with 3D Tokenizer），就获得了传统LLM所不具备的两大核心能力：**强大的3D空间理解和深刻的时序推理能力**。

理想MindVLA：L (语言)革命

革命点二：专为“车端芯片”而生的“架构”

- **MoE + 稀疏注意力（Sparse Attention）**：这是实现“低算力跑大模型”的核心。MindVLA采用了**MoE（混合专家）**架构。
 - 如图 1.4 所示，当一个“3D高斯特征”被输入时，它首先会经过一个“**路由器（Router）**”。
 - 路由器会“智能地”决定这个任务应该由哪个“专家”（E1, E2 ... E8）来处理。例如，一个“刹车”相关的Token可能被路由给“E1刹车专家”，一个“变道”相关的Token可能被路由给“E3变道专家”。
 - 这意味着，在任何一次推理中，**都只有一小部分专家（如2个）被激活**，而不是整个庞大的模型。它用“稀疏激活”换来了极高的推理效率。
- **并行解码（Parallel Decoding）**：这是实现“实时动作”的“杀手锏”。
 - 传统的LLM（如ChatGPT）生成文本是**自回归**的（auto-regressive），即一个字一个字地“蹦”出来（“我-今-天-很-高-兴”），这非常慢。
 - MindVLA巧妙地区分了“思考”和“行动”。当它需要输出“思维链”（CoT）来解释时，它可以慢慢地“蹦”字。但当它需要**输出动作（Action Tokens）**时，它采用了“**并行解码**”（Parallel Decoding）。
 - 如图右侧所示，Action Token 1（转向）、Action Token 2（油门）、Action Token 3（刹车）... 它们是在**一个步骤中被同时（in parallel）生成**的，而不是一个一个地“蹦”出来。这极大地压缩了生成动作的时间，是满足30Hz实时响应的工程关键。

创造了一个**天生懂3D、会推理、且为车端芯片深度优化**的“驾驶大脑”。这个“大脑”不再是“快慢双核”中那个笨拙、缓慢、只会“说教”的VLM，而是一个真正高效、统一的“决策核心”。


理想MindVLA: A (行动)革命: 从“轨迹点”到“Diffusion策略”

优势一：精细化与“拟人化”的动作

Diffusion模型极其擅长生成连续、平滑、且“风格化”的输出。这意味着它生成的驾驶轨迹，不再是冷冰冰的、由直线和圆弧构成的“机器轨迹”，而是精细化的、高度“拟人”的平滑轨迹。

正如理想的工程师所比喻的，这就像是经典的“旋轮线”（最速降线）问题：

- 传统的规划器可能找到一个“代数函数”（如一条斜线或抛物线），它能走，但可能很“颠簸”。
- 而Diffusion（扩散模型）则能通过“变分函数”找到那个物理上最优的“旋轮线”解。
- 这个解，就是那条在安全、效率和乘坐舒适度（如G值）之间达到完美平衡的“黄金轨迹”。



理想MindVLA：A (行动)革命：从“轨迹点”到“Diffusion策略”

优势二：从“反应”到“博弈”的集体建模

MindVLA的A模块并不仅仅在规划“我”（自车）该怎么走。它在做一个更高级的事情：“行为的集体建模”（Collective Modeling and Alignment of Behaviors）。

- **输入端融合了“他者”信息：**其核心处理模块（那个包含Multi-Head Self-Attention的Transformer结构）接收的**不仅仅是**代表自车意图的“VLA Guidance”，**还同时接收了“Multi-Agent Noise”**。这个“多智能体噪声”可以理解为模型对环境中其他关键智能体（如旁边的车辆、前方的行人）未来行为不确定性的一种表示或采样。
- **联合建模交互：**模块内部复杂的Multi-Head Self-Attention 等结构，使其能够**联合地**（Collectively）建模自车意图与其他智能体潜在行为之间的**复杂交互**。它不再是孤立地规划自车，而是在一个共享的空间中同时考虑“我”和“他”的未来可能性。
- **输出端预测“全局”未来：**最关键的是，其最终输出**不是一条**单独的自车轨迹，而是“Multi Agent Trajectories”（多智能体轨迹）。这意味着，MindVLA在生成“我”的最优轨迹的同时，**也在同步预测和生成“他”（如周围车辆、行人）的最可能轨迹**。

理想MindVLA：A (行动)革命：从“轨迹点”到“Diffusion策略”

这实现了从“反应式”到“博弈式”的进化：

- **简单的“反应式”系统**：就像一个新手司机，只看前车，“他刹车了，我再刹车”；“他变道了，我再减速”。这种系统缺乏预判，容易在复杂交互中措手不及。
- **MindVLA的“博弈式”系统**：它更像一个经验丰富的老司机，能够进行**预判和博弈**。通过对“Multi Agent Trajectories”的联合建模，它可以进行类似“**我猜测**那辆车可能会向我变道，**所以我**提前轻微减速并向右打一点方向以为他预留空间”这样的前瞻性规划。

如何实现“实时”？—— ODE Sampler

Diffusion（扩散模型）虽然强大，但它有一个众所周知的致命弱点：**慢**。

标准的Diffusion需要成百上千步的“去噪”迭代才能生成一张图。而自动驾驶的控制循环必须在30Hz（约33毫秒）内完成。

MindVLA的工程优化再次登场：它使用了“**基于常微分方程的ODE Sampler**”（**ODE采样器**）。

这个采样器极大地加速了Diffusion的生成过程。它不再需要“成百上千步”，而是可以将轨迹的“收敛”压缩到“**大概2到3步内完成**”。这个工程上的突破，才使得Diffusion这个“AIGC”技术，终于得以被塞进“自动驾驶”的实时控制循环中。

至此，MindVLA通过V、L、A三个模块的彻底革命，已经构建了一个能看懂3D世界、能思考、能生成完美动作的“统一大脑”。

但还有一个最后的问题：这个“大脑”生成的动作，如何确保是“安全”的、“舒适”的、并“符合人类价值观”的？

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

由华中科技大学和小米联合提出的ORION，则为我们展示了另一条同样巧妙、且更侧重于“对齐”（Alignment）的VLA实现路径

VLM顽疾——“**语义鸿沟**”。即，如何将VLM的“语义推理空间”（如“应减速”）优雅地“翻译”给“轨迹行动空间”（如 $[x, y, z, \dots]$ ）。

ORION 是一个“**通过视觉语言指令指导轨迹生成的端到端自动驾驶框架**”。它的架构设计精妙地回答了MindVLA也必须回答的两大难题：“如何处理时序？”和“如何弥合鸿沟？”

ORION的VLM（L模块）是整个系统的“决策中枢”。与MindVLA从零训练不同，ORION选择了一个强大的VLM基座，并赋予了它三大核心职责：

理解用户指令（如“在下一个路口左转”）。

理解当前视觉信息（如“前方有行人”）。

理解长时程的历史上下文（如“那辆车在10秒前就开始频繁变道”）。

ORION的VLM（L模块）会结合这三类信息，对驾驶场景进行**多维度的分析**。它不仅会输出“场景描述”或“关键物体行为分析”，更重要的是，它会进行“**历史信息回顾**”和“**动作推理**”（Action Reasoning）。

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

关键模块1：QT-Former（时序处理）

ORION 的L模块（语言核心）要负责的第一件事，就是理解长时程的历史上下文。

VLM通过“叠加多帧图像”来建模时序，会立刻撞上“Token长度限制”和“巨大计算开销”这两堵墙。你无法让VLM记住30秒前发生的事情，因为它的“上下文窗口”根本装不下这么多帧的图像Token。

ORION的第一个天才创新，就是引入了QT-Former（Querying Transformer-Former），一个基于查询的时间模块（a query-based temporal module），专门用来解决这个“时序瓶颈”。

QT-Former本质上是一个高效的“长时程记忆聚合器”。它彻底抛弃了“叠加所有帧”的笨办法，而是巧妙地引入了三种类型的可学习查询（learnable queries）和“记忆库”（Memory Bank）。




Figure 3. The detailed architecture of QT-Former. It accepts diverse queries and image features as inputs to detect traffic elements, predict motion, and aggregate long-term vision context.

它接收图像特征（Image Features）和三种查询（Perception, Scene, History Queries）作为输入，通过自注意力和交叉注意力机制处理信息，并利用记忆库（Long-term Memory Bank）来聚合历史上下文

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

QT-Former的工作流程

1、输入与查询初始化：

- QT-Former接收来自Vision Encoder 的当前帧**图像特征**（Image Features）。
- 同时，它初始化**三种可学习的查询向量**：
 - **感知查询**（Perception Queries）：用于提取与具体物体检测、运动状态和交通信号相关的细粒度信息。
 - **场景查询**（Scene Queries）：用于捕捉当前场景的整体关键信息，作为传递给下游LLM的“场景令牌”。
 - **历史查询**（History Queries）：用于与“记忆库”交互，提取相关的历史信息。

2、当前帧信息处理（循环x6次）：

- **查询间交互**: 感知查询和场景查询首先通过**自注意力**（Self-Attention） 机制相互交换信息。
- **特征提取**: 然后，这两种查询通过**交叉注意力**（Cross-Attention） 机制与当前帧的图像特征（Image Features） 进行交互，从中提取相关信息。这个过程会重复6次（x6）以充分提炼特征。
- **感知任务输出**: 经过处理的**感知查询**被送入多个辅助头（Auxiliary Heads），用于执行具体的感知任务，如**物体检测**（Detection）、**运动预测**（Motion）和**交通状态**（Traffic State）识别。
- **场景令牌生成**: 经过处理的**场景查询**则形成了代表当前场景关键信息的**场景令牌**（Scene Tokens）。

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

3、历史信息处理（循环x1次）：

- **记忆检索:历史查询**（History Queries）首先通过**交叉注意力**与**长期记忆库**（Long-term Memory Bank）进行交互。记忆库中存储了过去n帧（例如n=16）的历史查询结果，并通过**时间戳嵌入**（Timestamp）区分不同时刻的信息。这一步是为了“回忆”过去。
- **当前场景关联**：带着“回忆”的历史查询，再次通过**交叉注意力**与当前帧的**场景查询**（Scene Queries）进行交互。这一步是为了“提取当前场景中与历史最相关的细节”。
- **记忆更新**：经过当前场景信息更新后的历史查询，会被存入**记忆库**（遵循FIFO原则，替换掉最旧的记录），用于下一帧的“回忆”。

4. 输出与连接：

- 最终，经过处理的**场景令牌**（代表当前）和**历史令牌**（代表过去）会通过一个**MLP**（多层感知机）进行转换，然后一起被送入下游的**大语言模型**（LLM，即L模块）。

QT-Former的引入，为VLA带来了三大核心优势：

- **1. 解决了“时序瓶颈”**：VLM（L模块）不再需要处理海量的历史图像Token，它只需要处理QT-Former返回的那个小巧的“记忆特征”。这**极大地减少了计算开销**，并彻底摆脱了“Token长度限制”。
- **2. 增强了场景理解**：通过高效聚合长时程信息，QT-Former**增强了模型对历史场景的理解能力**。它能更准确地捕捉静态交通元素（如“我1分钟前路过的那个路牌”）和动态物体（如“那辆车在过去30秒一直在异常加速”）的运动状态。
- **3. 融合了历史与现在**：QT-Former使得模型能够将“**历史信息**”无缝地“**整合到当前的推理和动作空间中**”。L模块的决策（“规划Token”）不再是基于“当前这一帧”的“应激反应”，而是基于“过去1分钟”所有信息的“深思熟虑”。

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

关键模块2：VLM + 生成模型（弥合鸿沟）

ORION 提出了一种同样天才的“**解耦-对齐**”方案。

ORION的核心创新在于：它**并不强迫VLM（L模块）去直接生成那些它不擅长的、高精度的轨迹数值**。

1.L模块（VLM）只负责“思考”：

VLM（语言核心，ORION中使用Vicuna v1.5）在结合了用户指令（Instruction）、当前视觉信息（来自QT-Former的场景令牌）和历史信息（来自QT-Former的历史令牌）后，会进行复杂的“**动作推理**”（Action Reasoning），它的最终输出，不是一个轨迹，而是一个高度凝练、抽象的“**规划Token**”（Planning Token）。这个“规划Token”就是VLM“思考”的结晶，是它对“语义鸿沟”这边（推理空间）的最终答案。例如，这个Token可能就代表了“减速让行”或“坚决超车”的语义。

2.A模块（生成模型）只负责“执行”：

ORION引入了一个专门的A模块——一个**生成模型**（Generative Model），它可以是**VAE（变分自编码器）**或**扩散模型**（Diffusion Model）。这个生成模型（见图2.1（d）中的“Generative Planner”）的**唯一任务**，就是接收L模块传来的那个抽象的“规划Token”，并将其**作为“条件”**（Condition），来“生成”最终的、高精度的、多模态的驾驶轨迹。

小米/华科ORION：用“规划Token”弥合“语义鸿沟”

关键模块2：VLM + 生成模型（弥合鸿沟）

这种“VLM（思考）→ 规划Token → 生成模型（执行）”的架构，完美地解决了“语义鸿沟”：

- **专业分工：** VLM（L模块）专注于它最擅长的语义理解和逻辑推理（生成“规划Token”）。生成模型（A模块）则专注于它最擅长的数值拟合和轨迹生成。
- **弥合鸿沟：** “规划Token”成为了那座跨越“鸿沟”的桥梁。它既是L模块推理的“终点”，又是A模块生成的“起点”，从而**将VLM的“推理空间”与轨迹的“动作空间”完美地“对齐”（Alignment）**了。
- **全程可导：** 最重要的是，如图（d）所示，这个“规划Token”是可微分的，反向传播（Backpropagation）的“梯度流”（红色虚线）可以从最终的轨迹（A模块）一路畅通无阻地流回VLM（L模块）。

总结：

ORION 的架构（**VLM + QT-Former + 生成模型**）向我们展示了如何通过精妙的模块组合和“对齐”思想，将复杂的视觉问答（VQA）任务和轨迹规划（Planning）任务，优雅地**统一到了一个可以进行端到端优化的VLA框架中**。


无论是MindVLA 的“三位一体”重构，还是ORION 的“解耦-对齐”方案，它们都殊途同归——“组装”好一个“统一大脑”。



03

世界模型（World Model）与RLHF（人类反馈强化学习）

世界模型（World Model）与RLHF（人类反馈强化学习）



VLA的驾驶能力得以“飞速进化”：

数据 (Data)： 飞轮的“燃料”。


人类反馈 (RLHF)： 飞轮的“价值观”校准器。

世界模型 (World Model)： 飞轮的“无限加速器”。

世界模型（World Model）与RLHF（人类反馈强化学习）

“数据规模定律”：VLA的铁律

VLA的进化遵循着一条简单而残酷的铁律——“数据规模定律”（Data Scaling Law）。



VLA的“智商”是靠数据“喂”出来的。更多的驾驶数据（Clips）能线性地、可预地提升智驾性能（MPI）

世界模型（World Model）与RLHF（人类反馈强化学习）

数据的“质”远比“量”更重要

（视觉+语言+行动）三模态对齐的数据。

- 视觉（V）：这一帧的图像/雷达数据是什么？
- 行动（A）：此时驾驶员做了什么动作（转向 -2.3° ）？
- 语言（L）：驾驶员为什么这么做？（“因为我看到行人有探头的趋势”）

这种（V+L+A）三模态对齐的数据，尤其是覆盖“犄角旮旯”（corner-case）场景的，是“极其稀缺且昂贵”的。

如何获取“高质量”数据？VLA的“数据炼金术”

1. 炼金术一：从“沙子”中“淘金”（过滤与检索）
2. 炼金术二：用“AI”标注“AI”（自动标注）

世界模型（World Model）与RLHF（人类反馈强化学习）

人类反馈（RLHF）：对齐价值观

RLHF是VLA的“价值观校准器”。它的核心任务，不是“模仿”（Imitation），而是“对齐”（Alignment）。它负责将VLA的行为，对齐到人类真正“偏好”（Prefer）的价值观上，例如“安全”、“舒适”、“合规”。

步骤一：采样（Sampling）—— VLA “出题”

步骤二：奖励建模（Reward Model）—— 人类“打分”

步骤三：强化学习（RLHF）—— VLA “改正”

总结：

RLHF是VLA飞轮的“价值观校准器”。它让VLA不再是一个只会“模仿”人类驾驶员（包括其所有坏习惯）的“模仿者”，而是一个被人类“价值观”和“偏好”（Preference）深度“对齐”（Align）的“智能体”。

这才是VLA的终极目标：“对齐人类驾驶员的行为，提高安全驾驶的下限”。

世界模型（World Model）与RLHF（人类反馈强化学习）

世界模型 (World Model): 无限的训练场

MindVLA的“世界模型中的强化学习”（Reinforcement Learning in World Model at Scale）。

1. 基础：基于3DGS的场景表示 (Implicit Foundation)
 2. 核心魔法：“假如（What-if）”模拟与物理规律学习 (Progressive Scene Reconstruction)
 3. 提升真实感与生成能力 (Novel View Restoration)
 4. 整合入强化学习闭环 (Reinforcement Learning Loop)
- **流程**：VLA智能体（Agent）输出的**Trajectories**（轨迹）被送入**World Model**。World Model模拟执行该轨迹后的**后果**（即预测的未来状态或渲染的未来图像）。这个“后果”被送入**Reward Model**（奖励模型，即RLHF）进行打分。得分（奖励信号）再反馈给VLA智能体，指导其优化策略。
 - **价值**：世界模型提供了一个**安全、高效、可无限重复**的“虚拟训练场”，让VLA可以在其中进行大规模的“试错”学习，而无需承担真实世界的风险。

世界模型（World Model）与RLHF（人类反馈强化学习）

总体流程总结：

世界模型以高保真的3DGS场景表示为基础。

“**渐进式场景重建**”模块负责进行“**假如**”模拟：它从3DGS中采样不同轨迹（真实的和假设的），并渲染出对应的图像序列（Rendered Images）。这个过程让模型能够预测不同行动的视觉后果，并通过Loss计算 学习物理规律。

直接渲染出的图像（Rendered novel images）可能不够完美，因此它们被送入“**新视角重建**”模块。

该模块利用Denoising DiT（扩散模型），结合场景布局（Layouts）和噪声（Noisy Images），对渲染图像进行“**修复**”和“**增强**”，生成更高质量的“Restored Novel Images”。

这些高质量的模拟结果（无论是直接渲染的还是修复后的）最终被用于**强化学习闭环**：作为Reward Model的输入进行评估，或者作为VLA智能体学习的目标/状态表示。

MindVLA的世界模型 是一个基于3DGS 的强大生成式AI。它通过“**渐进式场景重建**” 学习物理因果律（模拟“**假如**”场景），通过“**新视角重建**”（利用DiT）提升真实感，最终为强化学习提供了一个安全、高效、可加速的“无限训练场”，驱动VLA智能体向“老司机” 快速进化。

世界模型（World Model）与RLHF（人类反馈强化学习）

“世界模型”的价值：7倍加速

“世界模型”为VLA提供了一个“无限的训练场”。RLHF（奖励模型）可以在这个“数字孪生世界”中，安全、高效、大规模地“惩罚”和“奖励”VLA的每一个“试错”轨迹。

这个“生成+模拟”的过程计算量是极其恐怖的。因此，MindVLA 采用了“NVIDIA NVAIE”进行“大规模部署”（Large Scale Deployment）。

其最终成果是惊人的：训练速度（Training Speed）提升了7倍（7x）。

总结：

“闭环飞轮”是VLA的“进化引擎”。

- 数据（Data）是“燃料”。
- RLHF 是“价值观校准器”。
- 而世界模型（World Model）则是“无限的训练场”。

这三个齿轮的紧密啮合，最终将一个VLA“新手”，“炼成”了一个真正无惧“长尾场景”、且“行为对齐”的“老司机”。



04

VLA带来的“物理智能体”新范式，VLA大规模落地的四大挑战

VLA带来的“物理智能体”新范式

“听得懂”：从“固定指令”到“自然语言理解”

“看得见”：从“依赖地图”到“实时视觉推理”

“找得到”：从“被动执行”到“主动推理规划”

“跑得通”：从“标准路况”到“攻克长尾场景”

四项革命性的“内在价值”：

思维能力 (CoT)： VLA具备了“思维链”（Chain of Thought）的推理能力。

沟通能力： VLA可以真正用“语言”（Language）与人类进行双向交流。

记忆能力： VLA拥有了“记忆”（Memory），能理解长时程的上下文（如ORION的QT-Former）。

自主学习能力： VLA拥有了“世界模型”和“RLHF”，具备了强大的“自主学习”进化能力。

VLA大规模落地的四大挑战

算力之墙 (Compute): 当“大脑”太重，塞不进“头盔”

VLA的“统一大脑” 功能强大，但也极其“沉重”。

- **参数量巨大：** 一个7B（70亿）参数的Llama 2 只是VLA “大脑” 的“起步价”。未来“基础驾驶大模型” 的参数量只会更大。
- **实时性要求苛刻：** 自动驾驶的控制循环必须达到30Hz（每帧约33毫秒）甚至更高，才能保证高速行驶时的安全响应。

将如此庞大的模型，塞进功耗和成本都极其受限的车端芯片（Edge Inference）——无论是英伟达的Orin-X 还是未来的THOR-U——并让它在33毫秒内完成一次“看->想->动”的完整推理，这几乎是一个“不可能的任务”。

这正是VLA落地的**最大工程瓶颈**。理想汽车强调，“在VLA时代，**推理算力比训练算力更重要**”。

目前的解决方案包括：

- **架构优化：** 采用MoE（稀疏激活） 和并行解码（Parallel Decoding） 等技术从根本上降低推理计算量。
- **模型压缩：** 通过硬件感知的量化（如FP8 / INT8 推理） 或知识蒸馏，将大模型压缩成适合车端部署的“微型VLA”。

VLA大规模落地的四大挑战

数据之渴 (Data): 当“燃料”稀缺且昂贵

VLA的“智商”是靠“（视觉+语言+行动）三模态对齐”的数据“喂”出来的。但这种高质量的“燃料”极其稀缺且昂贵。

- **收集成本高昂：** 获取一个包含“驾驶员内心想法”（语言L）的驾驶片段，远比录制一段普通视频（视觉V+行动A）要困难得多。Impromptu VLA 数据集 需要**手动标注8万个**驾驶片段，成本惊人。
- **覆盖“长尾”困难：** VLA最需要训练的，恰恰是那些最危险、最稀有的“犄角旮旯”（corner-case）场景。但这些场景在现实数据中本就罕见，获取足够的训练样本更是难上加难。
- **标注质量难以保证：** 即便有了（V+A）数据，如何精准地标注出对应的“语言”（L）——即驾驶员的“思维链”（CoT）——本身就是一个巨大的挑战。自动化标注流水线（如Chat-B2D）虽然高效，但其标注质量仍依赖于“教师VLM”的能力上限。

“数据”是VLA的生命线，但这条生命线正面临着“供给不足”的严峻挑战。

VLA大规模落地的四大挑战

安全之问 (Robustness): 当“大脑”产生“幻觉”

LLM（大语言模型）的引入，赋予了VLA强大的推理能力，但也打开了一个“潘多拉魔盒”：新的失效模式。

- **“幻觉” (Hallucination)**：这是LLM最臭名昭著的问题。如果VLA“幻觉”出一个不存在的障碍物并紧急刹车，或者“幻觉”出一个可以通过的绿灯而闯了红灯，后果不堪设想。
- **指令误解**：VLA能“听懂人话”，但也可能“听错”。它可能会错误地解析人类的口头俚语指令（例如将“floor it”——“踩满油门”理解为字面意思）。
- **环境噪声**：VLA必须在恶劣天气（雨、雪、眩光）导致的传感器数据损坏，以及充满背景噪音的语音指令下保持稳定。

更深层次的问题是：我们如何对一个由“自然语言”驱动的系统进行形式化的安全验证？传统的安全规则（如“红灯停”）是明确的，但VLA的决策过程充满了LLM的“黑箱”推理。虽然像SafeAuto那样引入基于逻辑的安全否决机制是第一步，但如何确保VLA的每一个决策都既“智能”又“绝对安全”，在很大程度上仍是未解难题。

VLA大规模落地的四大挑战

感知之差 (Perception): 当“用户觉得”不够惊艳

新事物认知需要时间: VLA是一个全新的概念, 大部分用户还没感知到它的价值。

价值在未来, 付费在现在: VLA的强大可能在将来 (如L3/L4), 但掏钱买车是现在。

L2->L2.9的“边际效用递减”: 最关键的是, 现有的L2/L2+ (非VLA) 系统已经做得相当不错了。VLA带来的提升, 更多是从“L2.5提升到L2.9”, 解决了那些“犄角旮旯”的长尾问题。但只要系统还停留在L2+ (需要驾驶员负责), 用户感知的核心差异就不大。

不止于车，VLA是通向“具身智能”的基石

理解了其成功的基石——强大的技术栈（V/L/A）和闭环飞轮（数据/RLHF/世界模型）；也正视了它在大规模落地前必须克服的四大挑战（算力/数据/安全/感知）

开源社区的OpenVLA项目，更是这一通用性的绝佳例证。

- **架构：** OpenVLA 采用了与自动驾驶VLA极其相似的技术栈：Llama 2 7B（L大脑） + DinoV2与SigLIP（V眼睛） + MLP动作解码器（A手脚）。
 - **训练：** 它在一个包含97万个真实世界机器人演示片段（如抓取、放置、擦桌子）的大规模数据集上进行了训练。
 - **成就：** 结果令人瞩目。OpenVLA在复杂的机器人操作任务上的成功率，全面超越了此前由谷歌闭源模型RT-2-X保持的记录。
 - **开放：** 更重要的是，OpenVLA将其数据、权重和代码全部开源，极大地推动了整个具身智能领域的发展
- VLA的发展将走向何方？麦吉尔大学和清华大学的综述 为我们指明了几个激动人心的方向：

基础驾驶（物理）大模型 (Foundation Models): 构建一个GPT风格的“物理世界骨干”模型，通过少量数据微调即可适配不同的车辆或机器人。

神经-符号安全内核 (Neuro-symbolic Kernels): 将VLA的“神经网络直觉”与“符号逻辑规则”相结合，为其决策提供“安全气囊”。

标准化交通（交互）语言 (Standardised Language): 让车辆之间（V2V），甚至人与机器人之间，能用一种标准化的“语言”高效协作。

